Massive Bank Transaction Big Data Pipeline

1 Milyon+ Satırlık Veride **Uçtan Uca İşleme, Tahminleme ve Görselleştirme.**

Proje Ekibi: Zeynep Palabıyık, Asude Çetin, Tuba Nur Aksın.

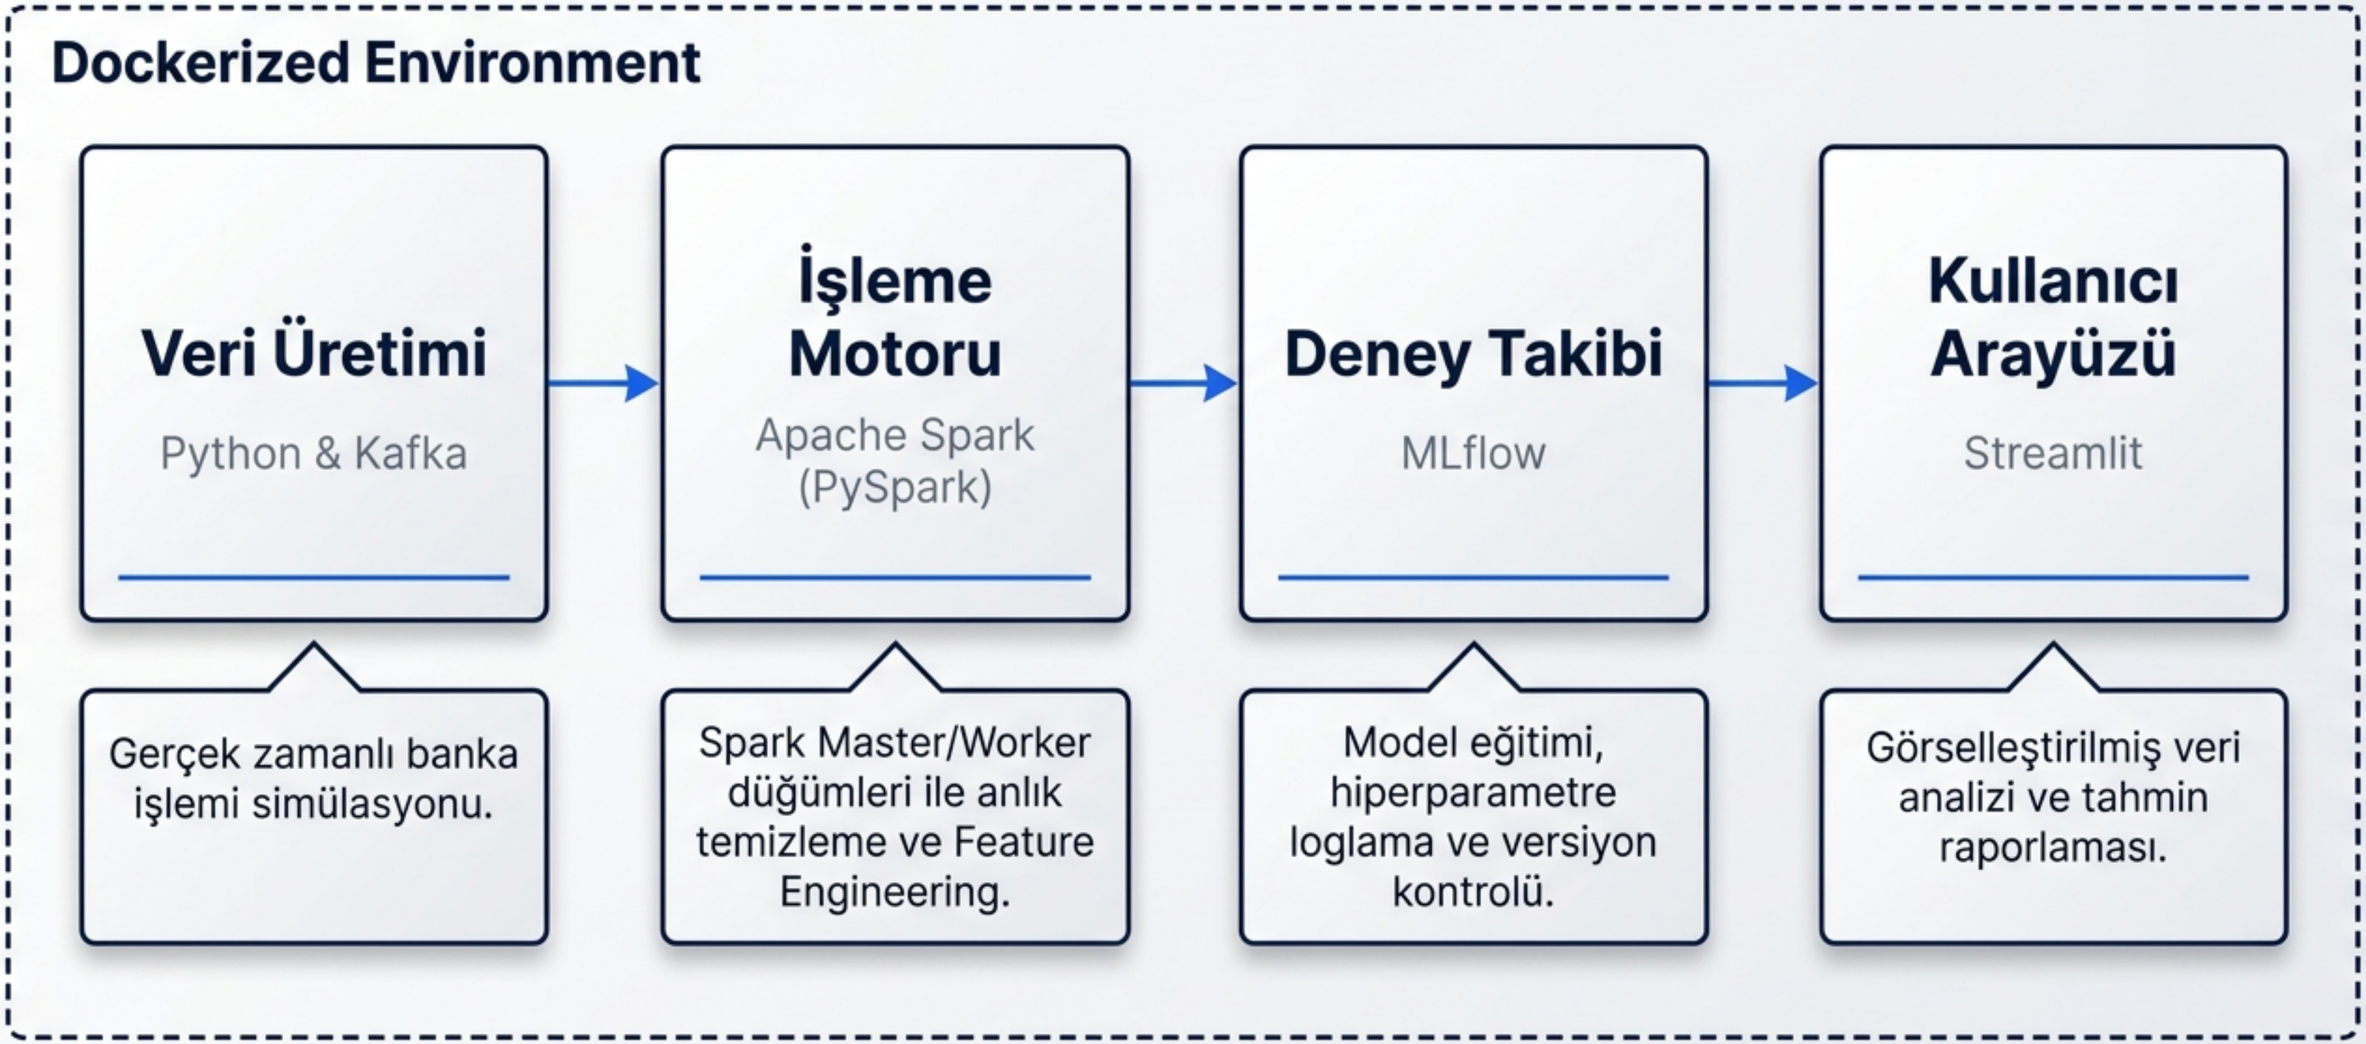
Veri Boyutu:
1 Milyon+ Satır

Mimari:
%100 Dockerized

Hedef:
Regresyon ve Analitik

NotebookLM

Uçtan Uca Teknik Mimari



NotebookLM

Veri Ön İşleme Süreçleri ve Sistem Optimizasyonu

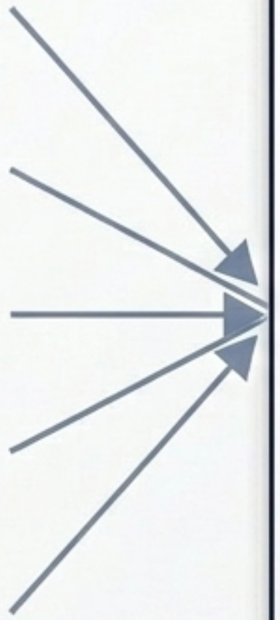
Sistem Zorluğu	Uygulanan Strateji	Mimari Sonuç
Bellek Yönetimi (OOM Hataları). 1M+ satırın Spark üzerinde yarattığı bellek taşması.	Veri tiplerinin küçültülmesi (Downcasting) ve Spark executor bellek ayarlarının optimizasyonu.	Kesintisiz batch ve stream veri işleme kapasitesi.
Gerçek Zamanlı Akış Tutarlılığı.	Kafka offset yönetimi ile senkronizasyon.	At-least-once teslimat garantisi ile kayıpsız veri aktarımı.
Veri Sızıntısı (Data Leakage). Geçmiş verilerin geleceği etkileme riski.	Model eğitiminde Time-Based Split (Zaman Bazlı Ayrım) stratejisi.	Güvenilir, gerçek dünya şartlarına uygun model testi.

NotebookLM

Karmaşık Özellik Mühendisliği (Feature Engineering)

Girdi: Ham Veri

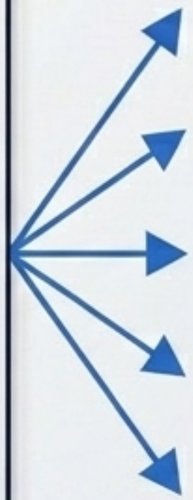
- Zaman damgası
- Ham tutar
- Lokasyon ID



Merkezi İşlem: PySpark Dönüşümleri

- **Target Encoding:** Kategorik değişkenlerin hedef değişkenle sayısal ilişkilerinin çıkarılması.
- **Interaction Terms:** Değişkenler arası çoklu korelasyonların modellenmesi.

Not: Dağıtık sistemlerde yüksek hesaplama maliyeti yaratan bu süreçler, PySpark'ın yerleşik fonksiyonları ile optimize edilmiştir.



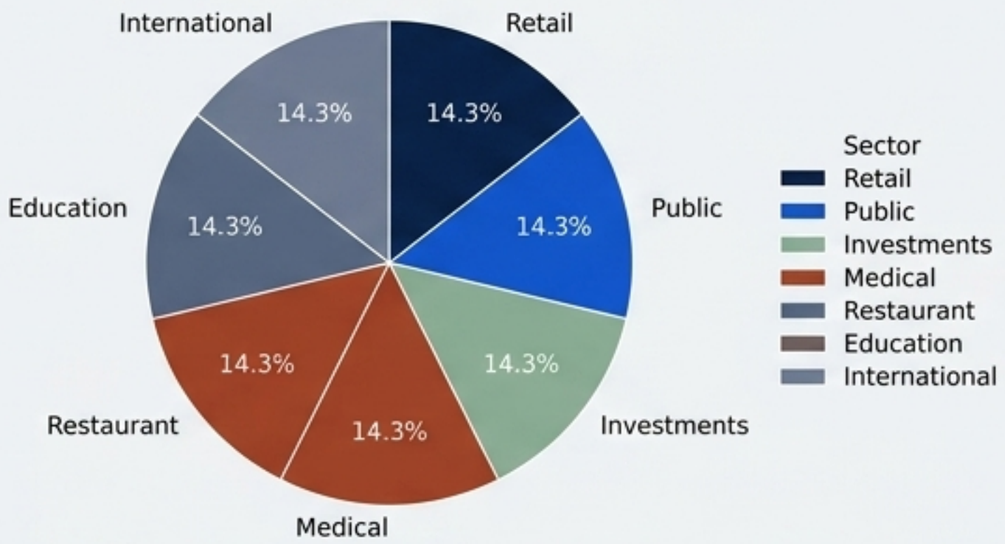
Çıktı: Analitik Veri Seti

- Zenginleştirilmiş
- Tahmin gücü yüksek
- transaction_intensity
- risk_scores

NotebookLM

Keşifsel Veri Analizi (EDA) - Sektörel ve Konumsal Dağılım

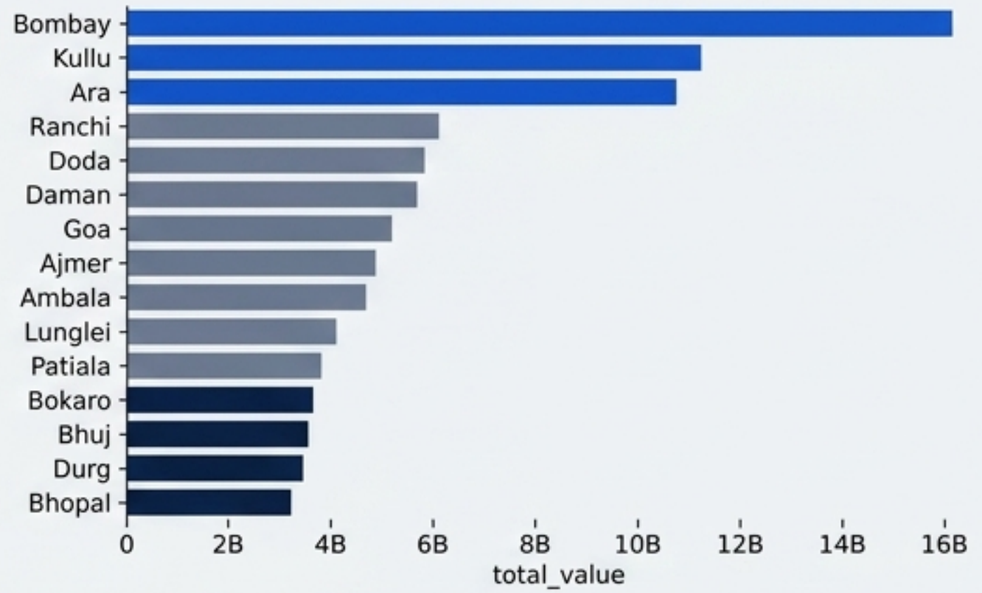
Domain Bazlı İşlem Dağılımı



Mükemmel Denge

Sektörler (Retail, Public, International, vb.) veri setinde %14.2 ile %14.3 arasında son derece **dengeli** bir dağılıma sahiptir.

Top 15 Lokasyon - Toplam İşlem Değeri

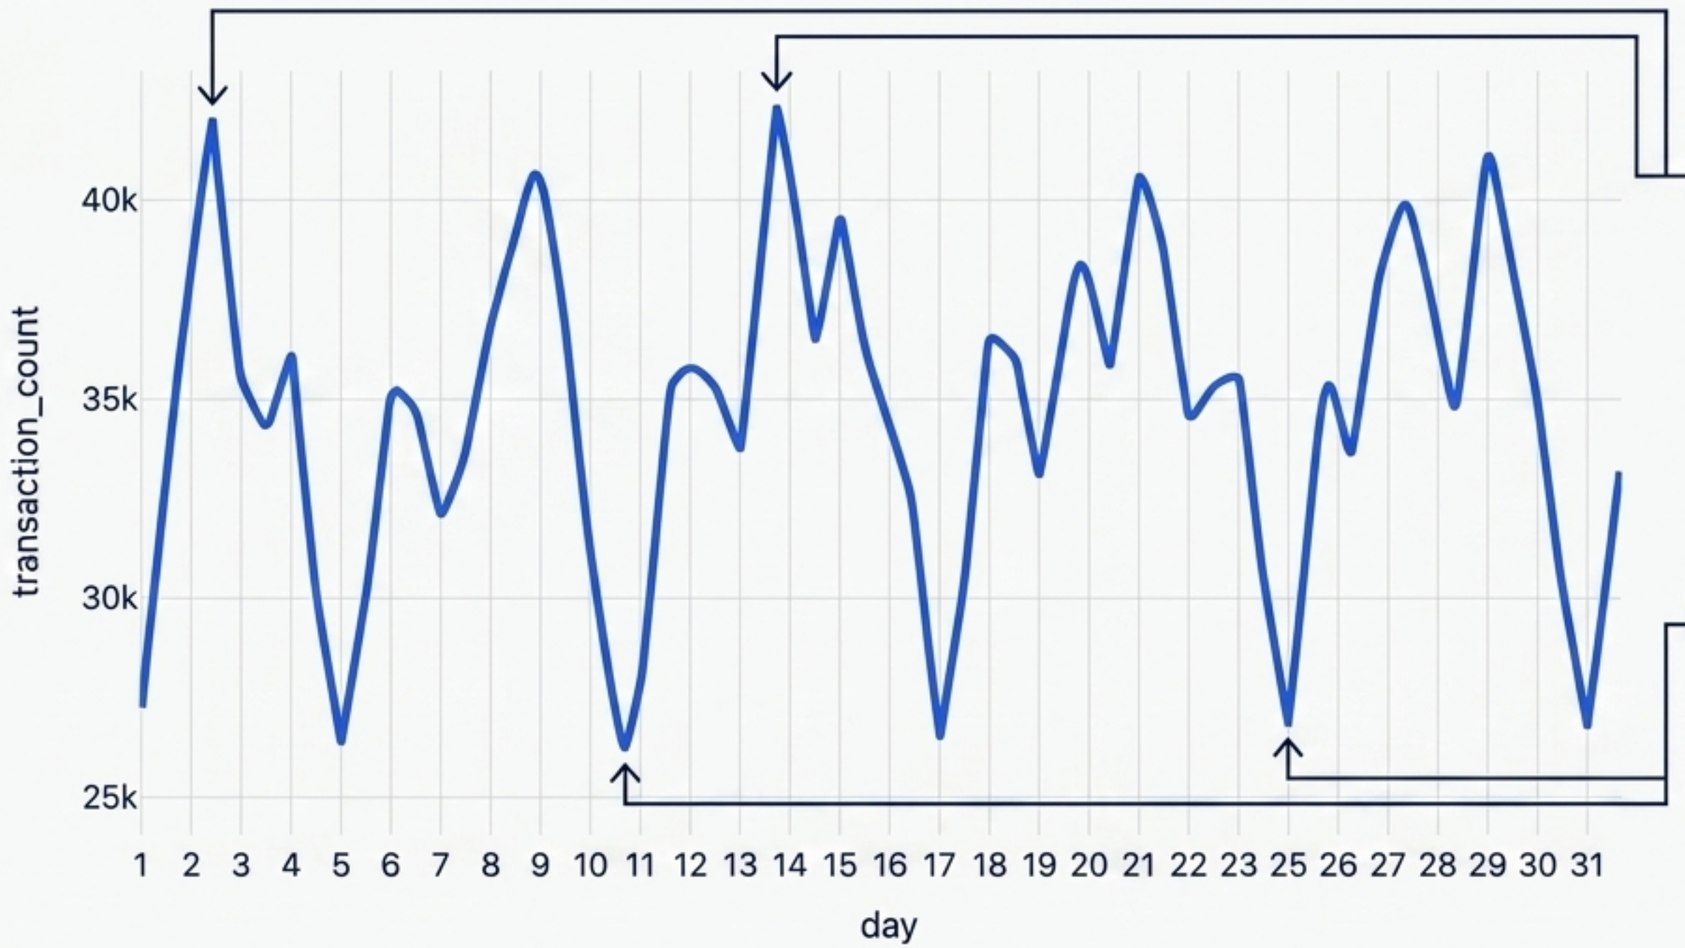


Hacim Merkezleri

Toplam işlem hacminde **Bombay, Kullu** ve **Ara** şehirleri başı çekmekte, bölgesel yoğunluğu net bir şekilde ortaya koymaktadır.

NotebookLM

Keşifsel Veri Analizi (EDA) - Zaman Serisi ve Ritmik Trendler



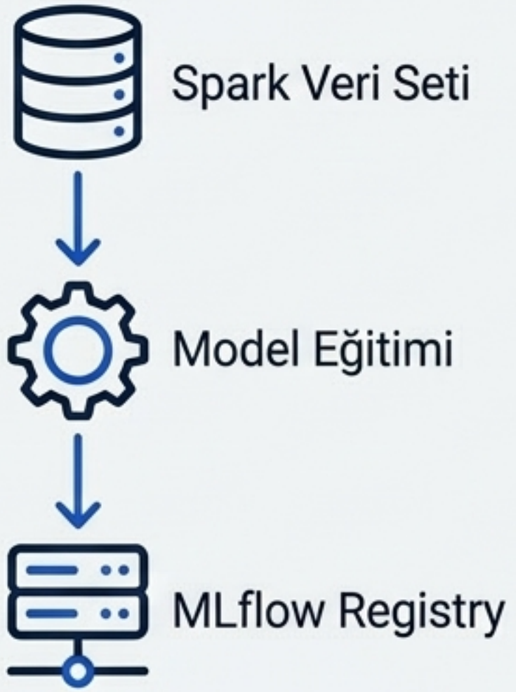
Döngüsel Davranışlar: 31 günlük zaman serisinde işlem sayılarında belirgin zirve ve dip noktaları tespit edilmiştir.

Sektörel Ritim: Bu periyodik dalgalanmalar, sistemin gün içi ve hafta sonu bankacılık davranışlarını (tatil günleri düşüşleri, mesai günleri yükselişleri) başarıyla yakaladığını kanıtlamaktadır.

NotebookLM

Makine Öğrenmesi Stratejisi ve Deney Takibi

MLflow Entegrasyonu



Tüm hiperparametreler, R^2 skorları ve model versiyonları MLflow ile şeffaf ve denetlenebilir şekilde loglanmıştır.

Test Edilen Modeller

1. **Gradient Boosted Trees (GBT)**
2. Decision Tree
3. Random Forest
4. Linear Regression
5. Generalized Linear Regression (GLR)

NotebookLM

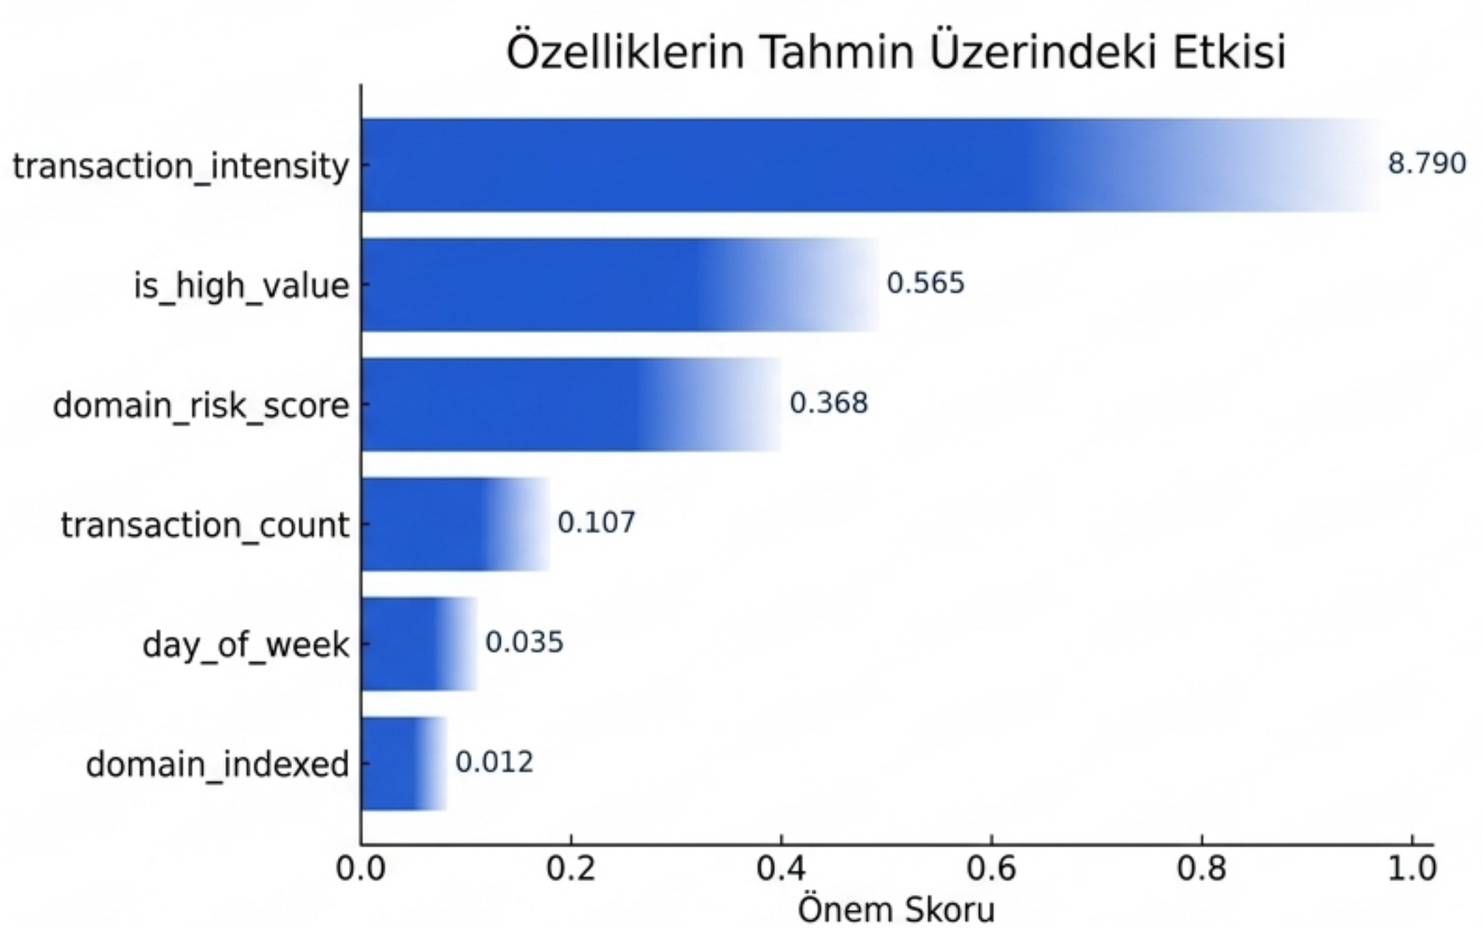
Model Değerlendirme Metrikleri: Performans Karşılaştırması

Heat-mapped Diagnostic Matrix			
Model	**R^2 Skoru (Başarı)**	**RMSE (Hata)**	**MAE (Hata)**
GBT Regressor	**0.892**	**85,863**	**67,082**
Decision Tree	0.873	93,252	72,063
Random Forest	0.834	106,600	87,332
Linear Regression	0.805	115,431	97,116
GLR	0.805	115,431	97,116

Sonuç: GBT Modeli, karmaşık veri yapılarını öğrenme kapasitesi sayesinde **0.892** R^2 skoru ile açık ara **en iyi performansı** sergilemiştir.

NotebookLM

Görselleştirilmiş Sonuçlar: Tahminleyici Özellik Önem Sırası



Analiz Özeti - Top 3 Faktör

1. transaction_intensity

Modelin tahmin üzerindeki en büyük etkisi bu değişkene aittir.

2. is_high_value

İşlemin yüksek değerli olup olmaması ikinci derecede kritik faktördür.

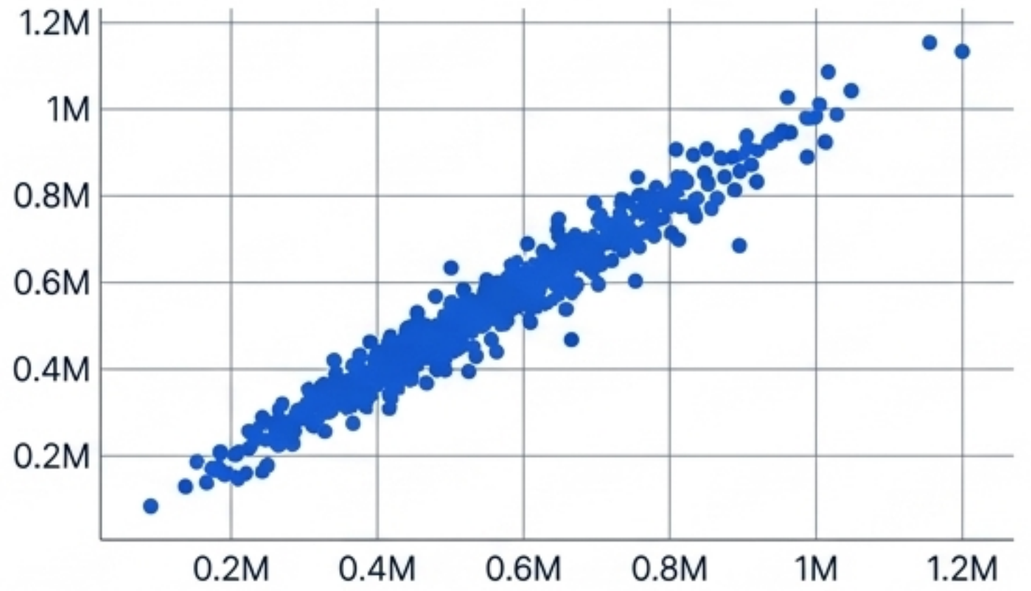
3. domain_risk_score

Algoritmanın, sektörel risk puanını tahmine doğrudan dahil ettiği kanıtlanmıştır.

NotebookLM

Görselleştirilmiş Sonuçlar: Hata ve Güvenilirlik Analizi

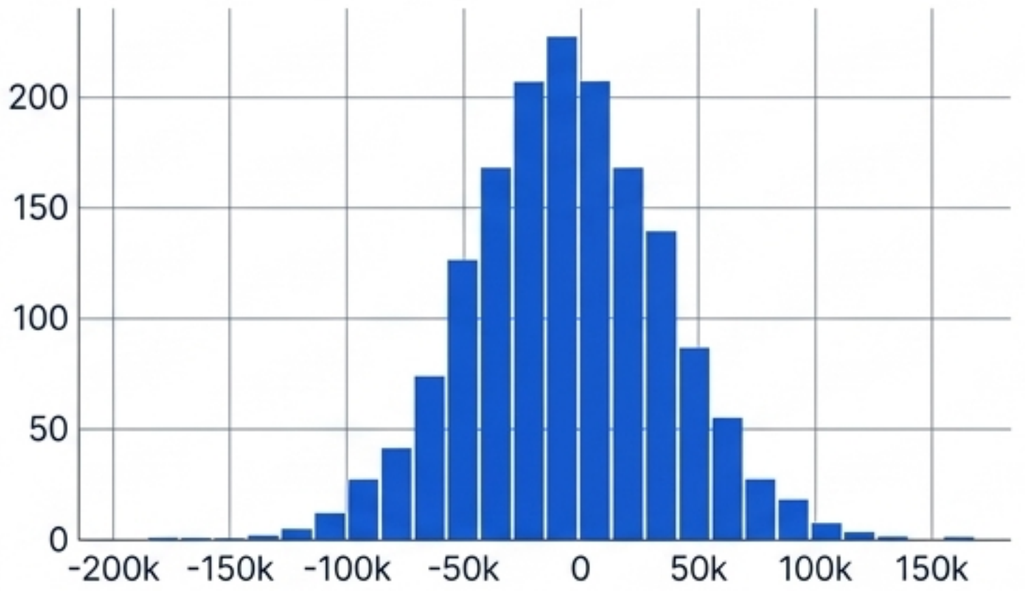
Gerçek vs Tahmin



Yüksek Korelasyon

Veri noktalarının diyagonal doğru etrafında sıkıca kümelenmesi, modelin gerçek değerleri yüksek bir hassasiyetle takip ettiğini gösterir.

Residual (Artık) Dağılımı

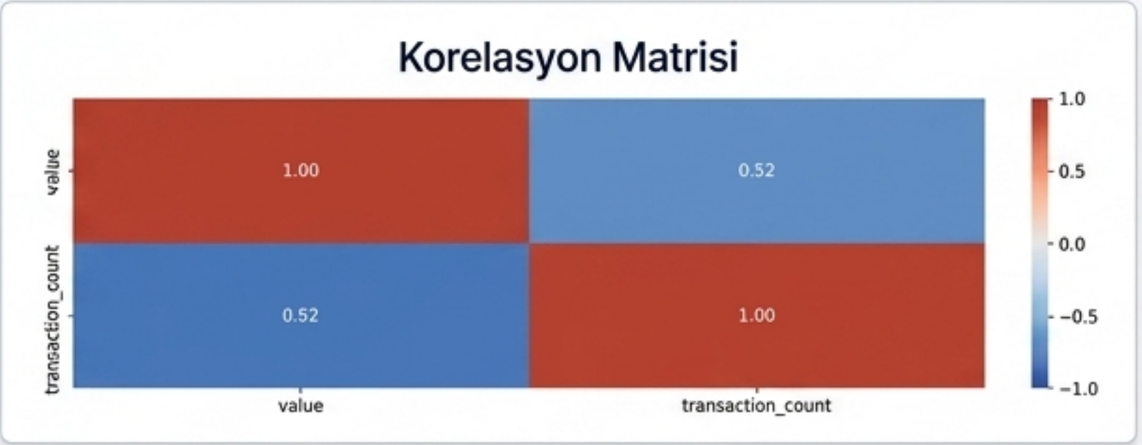


Sistematik Hata Yok

Artık dağılımının 0 noktasında merkezlenmesi ve kusursuza yakın bir çan eğrisi çizmesi, tahminlerin istatistiksel olarak güvenilir olduğunu kanıtlar.

NotebookLM

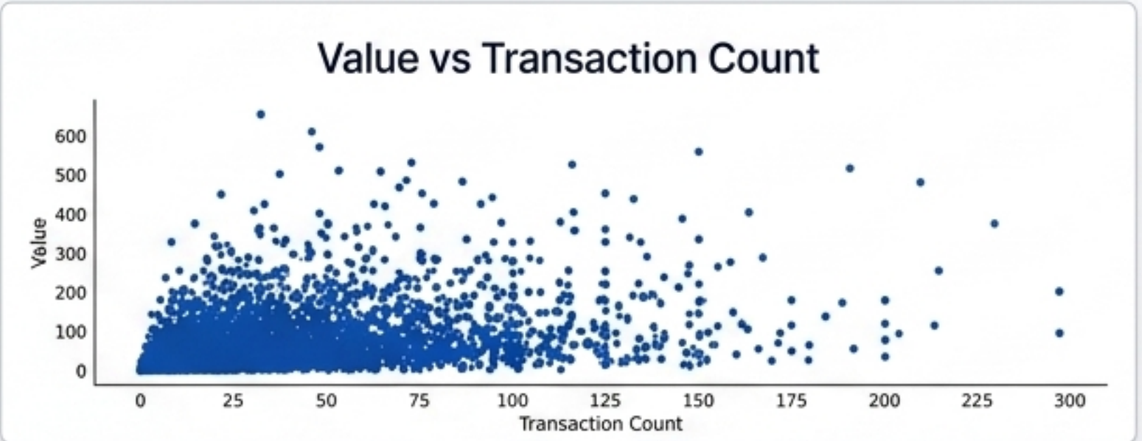
İnteraktif Dashboard: Derinlemesine Çok Boyutlu Analiz



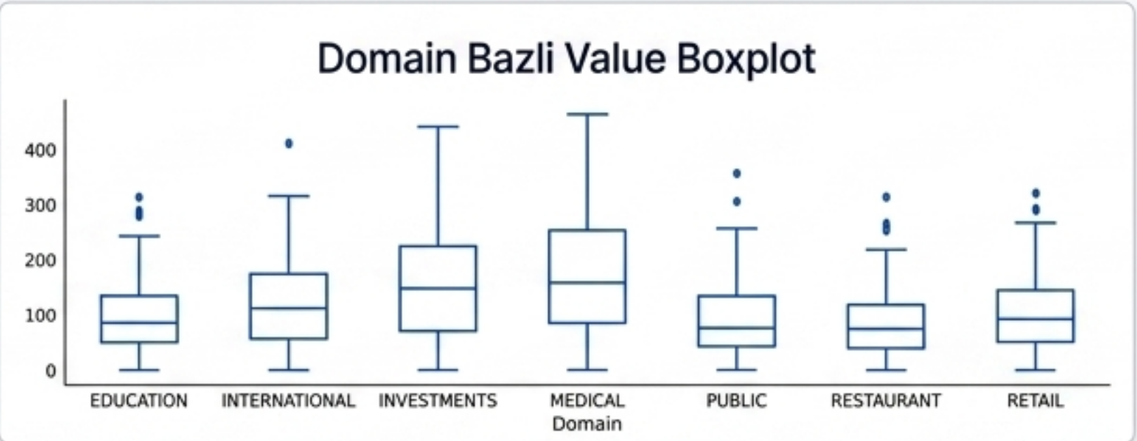
Korelasyon: Değişkenler arası doğrusal ilişkilerin anlık izlenmesi.



Olay Tipleri: İşlem tiplerine göre frekans dağılımı.



Dağılım: Aykırı değer (outlier) ve yoğunluk tespiti.



Kutu Grafiği: Sektörler arası medyan ve çeyreklik sapma analizleri.

NotebookLM

Temel Çıkarımlar ve Gelecek Vizyonu

Temel Çıkarımlar

- **Ölçeklenebilirlik:** Docker mimarisi sayesinde sistem, mevcut 1M+ satır kapasitesinden 10M+ satır işleme seviyesine kolayca ölçeklenebilir.
- **Doğruluk:** GBT modelinin üstün başarısı, finansal tahminlemede gelişmiş algoritmaların pratik değerini kanıtladı.
- **İzlenebilirlik:** Uçtan uca MLflow entegrasyonu ile model yönetimi şeffaf bir yapıya kavuştu.

Gelecek Yol Haritası

- **Gerçek Zamanlı Güvenlik:** Mimariye anlık Fraud (Dolandırıcılık) tespiti modülünün entegre edilmesi.
- **Derin Öğrenme Entegrasyonu:** Zaman serisi tahminleme gücünü maksimize etmek için LSTM/RNN tabanlı modellerin sisteme dahil edilmesi.

NotebookLM