BÜYÜK VERİ ANALİZİNE GİRİŞ DÖNEM PROJESİ TEKNİK RAPORU

Proje Adı: Massive Bank Transaction Big Data Pipeline
Proje Ekibi:

- Zeynep Palabıyık (220202016)
- Asude Çetin (220202060)
- Tuba Nur Aksın (220202078) **Kapsam:** Uçtan Uca Büyük Veri İşleme, Tahminleme ve Görselleştirme
  Veri Boyutu: 1 Milyon+ Satır Banka İşlemi
  Kaynak: Massive Bank Dataset (Kaggle)

1. Proje Mimarisi

Bu proje, modern büyük veri teknolojilerini kullanarak, devasa boyuttaki banka işlem verilerini gerçek zamanlı (streaming) ve toplu olarak işlemek üzere tasarlanmış, tamamen konteynırlaştırılmış (Dockerized) bir mimariye sahiptir.

1.1 Bileşenler ve Teknoloji Yığını

- **Veri Üretimi (Producer):** Gerçek dünya bankacılık senaryolarını simüle eden, 1 milyonun üzerinde satır üreten Python tabanlı Kafka Producer.
- **Mesaj Kuyruğu ve Akış Yönetimi:** Veri akışını düşük gecikme süresiyle yöneten **Apache Kafka** ve koordinasyon için **Zookeeper**.
- **İşleme Motoru:** Veri temizleme, özellik mühendisliği (Feature Engineering) ve model eğitimi süreçlerini üstlenen **Apache Spark (PySpark)**. Sistem hem Spark Master hem de Worker düğümleriyle ölçeklenebilir yapıdadır.
- **Deney Takibi:** Model parametrelerini, metriklerini ve versiyonlarını yönetmek için kullanılan **MLflow**.
- **Kullanıcı Arayüzü ve Görselleştirme:** Analiz sonuçlarını ve model performansını interaktif bir şekilde sunan **Streamlit Dashboard**.

1.2 İş Akışı

Mimari, verinin üretiminden son kullanıcıya sunulmasına kadar şu adımları izler:

1. Kafka Producer veriyi üretir ve ilgili topic'e basar.
2. Spark Streaming veriyi anlık olarak tüketir ve ön işleme tabi tutar.
3. ML modelleri batch olarak eğitilir ve en iyi model MLflow üzerinden kaydedilir.
4. Dashboard, kaydedilen modelleri ve geçmiş verileri kullanarak derinlemesine analizler sunar.

2. Karşılaşılan Zorluklar

Proje geliştirme sürecinde, büyük veri ekosisteminin doğası gereği çeşitli teknik zorluklarla karşılaşılmış ve bunlar optimize edilmiştir:

1. **Bellek Yönetimi (Memory Management):** 1 milyonun üzerindeki işlem verisinin Spark üzerinde işlenmesi sırasında Out-of-Memory (OOM) hataları yaşanmıştır. Bu durum, Spark yapılandırmasındaki executor bellek ayarlarının optimize edilmesi ve veri tiplerinin (downcasting) düzenlenmesiyle aşılmıştır.
2. **Gerçek Zamanlı Veri Akış Tutarlılığı:** Kafka'dan gelen verilerin Spark Streaming ile işlenirken senkronize edilmesi ve "at-least-once" teslimat garantisinin sağlanması için offset yönetimi titizlikle yapılmıştır.
3. **Karmaşık Özellik Mühendisliği:** Tahminleme doğruluğunu artırmak için uygulanan *Target Encoding* ve *Interaction Terms* gibi yöntemler, dağıtık sistemlerde yüksek hesaplama maliyeti yaratmıştır. Bu süreçler PySpark'ın yerleşik fonksiyonları kullanılarak optimize edilmiştir.
4. **Veri Sızıntısı (Data Leakage):** Zaman serisi niteliğindeki verilerle model eğitilirken, geçmiş bilgilerin geleceğe sızmasını önlemek amacıyla "Time-Based Split" stratejisi uygulanmıştır.

3. Sonuçlar ve Analizler

Dashboard çıktılarından elde edilen analiz sonuçları, sistemin hem operasyonel hem de analitik açıdan başarısını kanıtlamaktadır.

3.1 Keşifsel Veri Analizi (EDA) Çıktıları

- **Domain Dağılımı:** İşlemlerin sektörlere göre dağılımı (Retail, Public, International, Education vb.) oldukça dengelidir. Her bir sektör toplam hacmin yaklaşık **%14.2 - %14.3**'ünü oluşturmaktadır.
- **Lokasyon Analizi:** Toplam işlem hacminde Bombay, Kullu ve Ara gibi lokasyonlar başı çekmektedir. Bu durum, sistemin bölgesel bazda yoğunluk analizini başarıyla gerçekleştirdiğini gösterir.
- **Trend Analizi:** 31 günlük zaman serisi incelendiğinde, işlem sayısında haftalık bazda belirgin döngüler (peaks/troughs) gözlemlenmiştir. Bu periyodiklik, bankacılık işlemlerinin gün içi ve hafta sonu davranışlarını başarıyla yansıtmaktadır.

3.2 Makine Öğrenmesi Model Performansı

Sistem üzerinde 5 farklı regresyon algoritması test edilmiş ve karşılaştırılmıştır:

Model	R^2 Skoru (Başarı)	RMSE (Hata Payı)

GBT Regressor	**0.892**	**85,863**
Decision Tree	0.873	93,252
Random Forest	0.834	106,600
Linear Regression	0.805	115,431

Gradient Boosted Trees (GBT) modeli, **0.892 R^2 skoru** ile en yüksek performansı sergilemiş, karmaşık veri yapılarını öğrenme kapasitesini kanıtlamıştır.

3.3 Özellik Önem Sıralaması (Feature Importance)

Modelin tahminleme yaparken en çok dikkate aldığı değişkenler şunlardır:

1. **transaction_intensity:** Modelin tahmin üzerindeki en büyük etkisi bu değişkene aittir.
2. **is_high_value:** İşlemin yüksek değerli olup olmaması ikinci derecede kritiktir.
3. **domain_risk_score:** Sektörel risk puanı tahmini doğrudan etkilemektedir.

3.4 Regresyon Analizi ve Hata Dağılımı

"Gerçek vs Tahmin" grafikleri, modelin yüksek korelasyonla çalıştığını göstermektedir. Ayrıca, **Residual (Artık) Dağılımı** histogramı 0 noktasında merkezlenmiş ve normal dağılıma yakın bir çan eğrisi sergilemiştir. Bu, modelin sistematik bir hata yapmadığının ve tahminlerin güvenilir olduğunun göstergesidir.

4. Değerlendirme

Massive Bank Dataset projesi, büyük veri teknolojilerinin birbiriyle uyum içinde çalışabileceği uçtan uca bir pipeline'ın başarılı bir örneğidir.

Temel Çıkarımlar:

- **Ölçeklenebilirlik:** Mimari, Docker sayesinde kolayca ölçeklenebilir ve daha büyük veri setlerini (10M+) işleyebilecek kapasitededir.
- **Doğruluk:** GBT modelinin yüksek R^2 skoru, finansal tahminleme işlemlerinde gelişmiş algoritmaların başarısını teyit etmiştir.
- **İzlenebilirlik:** MLflow entegrasyonu, model geliştirme sürecini şeffaf ve denetlenebilir kılmıştır.